

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №2

По дисциплине: «Модели решения задач в интеллектуальных системах»
Тема: «Многослойный персептрон для задачи «исключающее ИЛИ» с числовыми классами: сравнение функций потерь MSE и Binary Cross-Entropy»

Выполнил:
Студент 4 курса
Группы ИИ-25
Заседатель Н.С.
Проверила:
Андренко К.В.

Цель работы: на основе многослойного персептрона архитектуры 2-2-1, реализованного в Лабораторной работе №1 для задачи XOR с числовыми классами c_0 и c_1 из диапазона $[-10; 10]$, реализовать альтернативную функцию потерь – бинарную кросс-энтропию (Binary Cross-Entropy, BCE) – и провести сравнительный анализ обучения сети с MSE (Лабораторная работа №1) и с BCE по скорости сходимости, качеству обучения и устойчивости к выбору начальных весов.

Задание:

- взять за основу код многослойного персептрона 2-2-1 из Лабораторной работы №1;
- поскольку BCE определена для выходов в диапазоне $(0; 1)$, а целевые значения в вашем варианте – произвольные числа c_0 и c_1 из диапазона $[-10; 10]$, реализовать нормализацию (масштабирование) целевых значений перед обучением и обратное преобразование выхода сети после обучения:
 - привести c_0 и c_1 к бинарным меткам 0 и 1;
 - обучать сеть на нормализованных целевых значениях с функцией потерь BCE;
 - при выводе результата преобразовывать выход сети $\hat{y} \in (0; 1)$ обратно в шкалу $[c_0; c_1]$.
- реализовать корректный градиент для связки BCE + сигмоида на выходном слое; для скрытого слоя градиент передаётся по стандартному правилу цепочки.
- обучить сеть на полной таблице истинности своего варианта (4 примера) в двух конфигурациях:

- **конфигурация А (базовая, из ЛР №1):** MLP 2-2-1, функция потерь MSE, целевые значения – исходные c_0/c_1 , выходной слой – сигмоида. Результаты можно взять из отчёта по ЛР №1 или, при необходимости, повторить обучение с фиксацией всех метрик.
- **конфигурация Б (новая):** MLP 2-2-1, функция потерь BCE, целевые значения – нормализованные $(0/1)$, с последующим пересчётом выхода в шкалу $[c_0; c_1]$.

Критерий остановки для обеих конфигураций одинаков – суммарная ошибка $E_s \leq E_e$ (используйте то же значение E_e , что и в ЛР №1, либо согласуйте новое значение отдельно для MSE и для BCE, поскольку это разные по своей природе величины – обоснуйте выбор в отчёте);

- для каждой конфигурации зафиксировать:
 - количество эпох до достижения критерия остановки (либо факт недостижения за максимально допустимое число эпох);
 - итоговую суммарную ошибку;
 - ассигасу на всех 4 примерах таблицы истинности;
 - среднюю абсолютную ошибку в исходной шкале $[c_0; c_1]$.
- провести не менее 5 запусков обучения для каждой конфигурации с разной случайной инициализацией весов (менять seed) и сравнить устойчивость сходимости: в скольких из 5 запусков сеть достигла критерия остановки, и какой разброс по числу эпох наблюдается;

- построить общий график зависимости суммарной ошибки от номера эпохи для конфигурации А (MSE) и конфигурации Б (BCE) на одних осях (для представительного запуска каждой конфигурации);
- реализовать блок визуализации результатов, включающий:
 - **график сходимости**– суммарная ошибка E_s от номера эпохи, конфигурации А и Б на одних осях, разными цветами/стилями линий, с обозначением порога E_e ;
 - **диаграмму разброса числа эпох по 5 запускам**(bar chart или scatter) для конфигурации А и конфигурации Б – наглядно показывающую устойчивость сходимости из п. 6 (например, столбики числа эпох для каждого из 5 seed, сгруппированные по конфигурации; запуски, не достигшие критерия останова, отметить отдельно, например штриховкой или отдельным цветом);
 - **визуализацию разделяющей поверхности скрытого слоя** – для представительного обученного экземпляра каждой конфигурации построить на плоскости (А, В) карту выходного значения сети (heatmap или contour plot) с наложенными точками обучающей выборки (4 примера таблицы истинности), закрашенными по истинному классу. Диапазон осей А и В – $[-10; 10]$ (весь допустимый диапазон входных значений). Для конфигурации Б цветовую шкалу можно строить как по нормализованному $\hat{y} \in (0; 1)$, так и по пересчитанному значению в шкале $[c_0; c_1]$ – выбрать более наглядный вариант и обосновать выбор;
 - **диаграмму сравнения точности восстановления шкалы**– столбчатую диаграмму средней абсолютной ошибки для конфигурации А и конфигурации Б, чтобы наглядно сопоставить точность регрессии к исходной шкале $[c_0; c_1]$.

Каждый график должен иметь подписанные оси, заголовок и легенду (где применимо). Разделяющую поверхность и графики точности рекомендуется разместить рядом (например, subplot 2×2 или отдельными рисунками) для удобства сравнения в отчёте;

- реализовать режим функционирования сети: пользователь вводит пару чисел (А, В) из диапазона $[-10; 10]$ (не обязательно совпадающих с c_0 и c_1). Сеть должна выводить:
 - выход в нормализованной шкале $\hat{y} \in (0; 1)$ (с точностью до 4 знаков);
 - выход, пересчитанный в исходную шкалу $[c_0; c_1]$ по формуле из п. 2;
 - к какому классу (c_0 или c_1) ближе полученное значение.

Продемонстрировать работу режима функционирования на всех 4 примерах исходной таблицы истинности и не менее чем на 2–3 дополнительных парах (А, В), не входящих в обучающую выборку.

Вариант 6 ($c_0 = -9, c_1 = 6$)

А	В	$A \oplus B$
-9	-9	-9
-9	6	6
6	-9	6
6	6	-9

Изменения в архитектуре и алгоритме относительно ЛР1:

Архитектура сети (2-2-1, сигмоида на всех слоях) не менялась. Изменения – только в целевой функции и, дополнительно, во входной нормализации:

Нормализация целей (как и в ЛР1, поскольку сигмоида на выходе ограничена (0;1) и не может выдать −9 или 6):

$$y_{norm} = \frac{y - c_0}{c_1 - c_0}$$

Обратный пересчёт после обучения:

$$y = y_{norm} \cdot (c_1 - c_0) + c_0$$

Вывод градиента для связки ВСЕ + сигмоида (выходной слой):

Потери для одного примера:

$$L = -y \ln p - (1 - y) \ln(1 - p), \quad p = \sigma(z) = out$$

Цепное правило:

$$\frac{\partial L}{\partial z} = \frac{\partial L}{\partial p} \cdot \frac{\partial p}{\partial z}$$

где

$$\frac{\partial L}{\partial p} = -\frac{y}{p} + \frac{1 - y}{1 - p}, \quad \frac{\partial p}{\partial z} = p(1 - p)$$

Подставляем и сокращаем:

$$\frac{\partial L}{\partial z} = \left(-\frac{y}{p} + \frac{1 - y}{1 - p} \right) p(1 - p) = -y(1 - p) + (1 - y)p = p - y$$

Итог:

$$\delta_{out} = out - y$$

Градиент для скрытого слоя:

$$\delta_h = (\delta_{out} W_2^T) \odot h(1 - h)$$

Результаты обучения (5 запусков, разные seed):

MSE:

seed	эпох	ошибка	accuracy	MAE
1	2557	0.009998	1.00	0.7445
2	10000	0.517550	0.75	3.8784
3	2772	0.009998	1.00	0.7444
4	2847	0.009998	1.00	0.7445
5	2844	0.009999	1.00	0.7445

BCE:

seed	эпох	ошибка	accuracy	MAE
1	2115	0.009996	1.00	0.0374
2	2148	0.009999	1.00	0.0374
3	2247	0.009995	1.00	0.0374
4	2150	0.010000	1.00	0.0374
5	2151	0.010000	1.00	0.0374

Сравнение на одном seed=4:

	MSE	BCE
эпохи	2847	2150
итоговая ошибка	0.009998	0.010000
accuracy	1.0	1.0
MAE	0.7445	0.0374

Блок визуализации:

График сходимости:





Диаграмма числа эпох по 5 запускам:



Разделяющая поверхность:






Диаграмма MAE:



Режим функционирования (ВСЕ-модель)

Предсказания MSE

(-9,-9) | $y_{\text{norm}}=0.0464$ | $y=-8.304$ | $\text{class}=-9$ | $\text{expected}=-9$

(-9, 6) | $y_{\text{norm}}=0.9411$ | $y=5.117$ | $\text{class}=6$ | $\text{expected}=6$

(6,-9) | $y_{\text{norm}}=0.9546$ | $y=5.320$ | $\text{class}=6$ | $\text{expected}=6$

(6, 6) | $y_{\text{norm}}=0.0479$ | $y=-8.282$ | $\text{class}=-9$ | $\text{expected}=-9$

Предсказания BCE

(-9,-9) | $y_{\text{norm}}=0.0022$ | $y=-8.967$ | $\text{class}=-9$ | $\text{expected}=-9$

(-9, 6) | $y_{\text{norm}}=0.9967$ | $y=5.950$ | $\text{class}=6$ | $\text{expected}=6$

(6,-9) | $y_{\text{norm}}=0.9978$ | $y=5.967$ | $\text{class}=6$ | $\text{expected}=6$

(6, 6) | $y_{\text{norm}}=0.0023$ | $y=-8.966$ | $\text{class}=-9$ | $\text{expected}=-9$

Режим функционирования BCE

Введите А В из диапазона [-10; 10]

Для выхода: letmeleavepls

А В [-10 10]: -9 -9

Нормализованный выход: 0.0022

Выход в исходной шкале: -8.9671

Ближайший класс: -9

А В [-10 10]: -9 6

Нормализованный выход: 0.9967

Выход в исходной шкале: 5.9502

Ближайший класс: 6

А В [-10 10]: 6 -9

Нормализованный выход: 0.9978

Выход в исходной шкале: 5.9670

Ближайший класс: 6

А В [-10 10]: 6 6

Нормализованный выход: 0.0023

Выход в исходной шкале: -8.9661

Ближайший класс: -9

А В [-10 10]: 5 5

Нормализованный выход: 0.0023

Выход в исходной шкале: -8.9662

Ближайший класс: -9

А В [-10 10]: 0 0

Нормализованный выход: 0.0022

Выход в исходной шкале: -8.9665

Ближайший класс: -9

А В [-10 10]: -6 6

Ошибка ввода. Пример: -3 7

А В [-10 10]: -6 6

Нормализованный выход: 0.9933

Выход в исходной шкале: 5.8992

Ближайший класс: 6

Вопросы:

1. Какая функция потерь дала более быструю/устойчивую сходимость?

BCE – быстрее (2115–2247 эпох против 2557–2847 у MSE) и заметно устойчивее (сошлись все 5 запусков, у MSE один из пяти застрял в локальном минимуме). Это согласуется с теоретическим преимуществом BCE: градиент связки BCE+сигмоида равен просто $(out - y)$ и не гаснет при насыщении выхода, тогда как у MSE градиент содержит множитель $out(1-out)$, который стремится к нулю при насыщении сигмоиды – отсюда более медленное и менее надёжное обучение (эффект «исчезающего градиента»).

2. Как нормализация целей повлияла на обучение по сравнению с обучением на «сырых» числах $[-10;10]$?

Напрямую на $c0/c1$ без нормализации обучение с сигмоидой на выходе вообще невозможно: сигмоида ограничена $(0;1)$ и никогда не выдаст -9 или 6 , поэтому суммарная ошибка застревает на уровне сотен и критерий $E_e=0.01$ недостижим в принципе (проверено: после 5000 эпох ошибка ≈ 234). Нормализация – не опция, а обязательное условие корректной работы сигмоидного выхода.

3. Точность восстановления шкалы $[c0;c1]$: MSE vs BCE, есть ли компромисс?

MAE у BCE (~ 0.037) на два порядка меньше, чем у MSE (~ 0.74). Компромисса не обнаружено: BCE выигрывает и по устойчивости классификации, и по точности регрессии к исходной шкале, поскольку логистическая ошибка сильнее «выталкивает» выход к $0/1$, а после денормализации это даёт значения, очень близкие к истинным $c0/c1$.

4. Устойчивость к случайной инициализации весов?

MSE – неустойчива: часть запусков (в нашей серии – 1 из 5) попадает в локальный минимум с accuracy 0.75. BCE – устойчива: все 5 запусков сошлись к $E_e=0.01$ с близким числом эпох (разброс всего ~ 130 эпох).

5. Подтвердилось ли наблюдение о линейной неразделимости XOR независимо от числовых меток?

Да, полностью: та же архитектура 2-2-1 со скрытым слоем успешно решает задачу для $c0=-9/c1=6$, как и для классического $0/1$ в ЛР1 – линейная неразделимость определяется структурой данных XOR, а не конкретными значениями меток классов.

6. Как выбор функции потерь соотносится с необходимостью скрытого слоя?

Никак не влияет на этот вывод – он определяется исключительно архитектурой. И MSE, и BCE обучались на одной и той же сети со скрытым слоем; функция потерь меняет лишь скорость и устойчивость сходимости, но не принципиальную возможность разделить линейно неразделимые данные – это обеспечивает только наличие скрытого слоя.

7. Что показывает визуализация разделяющей поверхности?

Граница у обеих конфигураций – две параллельные диагональные линии, отделяющие $(-9,-9)/(6,6)$ от $(-9,6)/(6,-9)$, что соответствует ожидаемой для XOR форме (пересечение двух полуплоскостей скрытого слоя). По расположению границы MSE и BCE визуально почти совпадают (решается одна и та же задача одной архитектурой); различие – в «резкости» карты значений: у BCE переходы цвета контрастнее из-за более сильного насыщения выхода, у MSE – более плавный, размытый градиент.

Вывод: реализовал альтернативную функцию потерь – бинарную кросс-энтропию (Binary Cross-Entropy, BCE) – и провёл сравнительный анализ обучения сети с MSE и с BCE по скорости сходимости, качеству обучения и устойчивости к выбору начальных весов.